

作品编码: 596098

2026年度中国青年科技创新“揭榜挂帅”擂台赛
学生赛道
报名表

推报学校名称: 湖南大学
揭榜榜题名称: XH-202619 基于国产开源大模型的AI Scientist技术研发与示范应用
(以发榜单位对外发布的榜题名称为准, 请勿改动)
榜题发榜单位: 浙江阿里巴巴云计算有限公司
申报作品名称: HypoWeaver-Qwen: 面向社会科学实证研究的证据驱动型 AI Scientist
申报者姓名: 陈俊希 陈昶泽 王星尧 陈卓然 程子桐 曾希程 朱珈冉 陈灿 车书瑶 李雨澄
(全部成员, 按顺序填写, 且不可更改)

第1页, 共3页

申报者情况	姓名	陈俊希		性别	男	出生年月	2006-08-17	
	所在学校及院系	湖南大学金融与统计学院						
	在读学历	本科		专业	精算学			
	年级	本科二年级		学制	4年	入学时间	2024	
	作品全称	HypoWeaver-Qwen: 面向社会科学实证研究的证据驱动型 AI Scientist						
	毕业论文题目	无						
	通讯地址	湖南省长沙市湖南大学金融与统计学院				邮政编码	410006	
					联系电话	19313000629		
合作者情况	姓名	性别	出生年月	学号	在读学历	年级	所在学校及院系	
	陈昶泽	男	2006-03	202418120128	本科	二年级	湖南大学金融与统计学院	
	王星尧	女	2006-03	202418030103	本科	二年级	湖南大学金融与统计学院	
	陈卓然	男	2007-02	202418030118	本科	二年级	湖南大学金融与统计学院	
	程子桐	女	2007-01	202518110127	本科	一年级	湖南大学金融与统计学院	
	曾希程	男	2006-07	202418110407	本科	二年级	湖南大学金融与统计学院	
	朱珈冉	女	2006-09	202418120116	本科	二年级	湖南大学金融与统计学院	
	陈灿	女	2002-12	S2518W1591	硕士	一年级	湖南大学金融与统计学院	
	车书瑶	女	2006-09	202418110206	本科	二年级	湖南大学金融与统计学院	
	李雨澄	女	2005-10	202418120127	本科	二年级	湖南大学金融与统计学院	
指导老师情况	姓名	性别	出生年月	职称		工作单位及职务		
	唐国家	男	1989-06	副教授		湖南大学金融与统计学院 湖南大学金融科技与工程系副主任		
	周斌	男	1995-03	讲师		湖南大学金融与统计学院 团委书记		
资格认定1	学校学籍管理部门意见		经审核, 以上全部参赛学生作者为2026年6月1日以前正式注册的全日制非成人教育的各类高等院校在校本科、本科生、硕士生、博士生(不含在职研究生)					
			湖南大学金融与统计学院 审核单位名称: 审核单位公章: 2026 月 日					

第2页, 共3页

挑战杯系统报名时参赛作品名称	HypoWeaver-Qwen：面向社会科学实证研究的证据驱动型 AI Scientist
选题	赛道一-选题 1-B
参赛作品简介	HypoWeaver-Qwen：本项目基于国产开源大模型千问，构建面向社会科学实证研究的多智能体 AI Scientist，率先聚焦绿色金融领域。系统以文献、政策与数据为输入，融合证据检索、事实抽取与知识图谱，识别研究缺口、生成可证伪假设，开展因果与统计研究设计、代码执行验证及多智能体审稿，形成“证据整合—假设生成—实验规划—执行验证—反馈迭代”的科研闭环。通过证据溯源、人工审核与结论核验，提升研究的可信度与可复现性，为绿色金融政策评估、碳市场机制与企业绿色创新研究提供智能辅助，并可拓展至保险精算、市场治理与风险监管等场景。
参赛作品使用 Qwen 大模型及 AI 技术说明	本作品通过阿里云百炼调用 Qwen3.7-plus，承担问题理解、事实抽取、假设生成、研究规划与多角色审稿，以 Qwen3-VL-Plus 解析科研图表与表格。系统融合检索增强生成（RAG）、BGE 语义向量、余弦相似度排序与知识图谱，通过文献配额提升证据多样性，为模型推理提供可追溯依据；采用类型化多智能体 workflow、证据上下文构建、结构化输出校验与有界修复，将评审反馈回注下一轮检索和规划。研究计划经数据与方法校验后，结合因果与统计分析、代码执行及独立统计复算，支持结果驱动的方案迭代；通过引用核验、人工审核与结论证据约束降低模型幻觉风险，形成“证据检索—假设推理—实验规划—执行验证—反馈修订”的智能科研闭环。
宣传视频链接/其他作品相关文件链接	链接： https://pan.quark.cn/s/88ece41acb42

摘要

人工智能正从知识检索与辅助写作逐步走向参与科学研究，但现有大模型在社会科学实证任务中仍面临证据来源难以追踪、研究问题在多层生成中发生偏移、研究方案与真实数据脱节，以及统计结果被过度解释等问题。针对上述挑战，本项目研发了面向社会科学绿色金融领域实证研究的证据驱动型 AI Scientist——

HypoWeaver-Qwen。系统基于阿里云百炼平台接入 Qwen 文本与视觉模型，以“问题提出—证据溯源—假设构建—研究设计—数据执行—结论审查”为科研主线，组织研究任务主持、文献与证据分析、科学假设设计、数据与方法设计、批判性审查、实验执行与复核等智能体协同工作。系统通过多来源证据检索与出处绑定保证研究依据真实可查，通过角色化上下文工程保持原研究问题，通过数据来源、变量定义和识别策略检查判断研究方案能否实际执行，并将语言模型推理与确定性统计程序、独立复算和科学结论审查相结合，形成从自然语言研究问题到标准化研究计划、实证结果和可复现材料的完整闭环。

系统首先基于已收集的绿色金融文献、政策资料，构建研究图谱，对研究主题、变量关系、理论机制与方法路径进行联合检索与关联分析，形成候选研究空白和可验证研究问题。研究团队综合考虑科学价值、公开数据可得性与方法可执行性，选取“碳市场能否促进企业高质量绿色技术创新”作为端到端实证研究案例。围绕该问题，系统综合来自 7 篇文献的 12 个全文片段，构建政策激励、融资约束与企业异质性等可证伪假设，并在数据审查中发现，现有公开面板止于 2021 年，缺乏全国碳市场启动后的充分结果期，且尚未与官方履约企业名单完成绑定。系统据此保留全国碳市场研究命题，将当前可执行任务界定为区域碳政策公开复现。基于 2010—2021 年 1,183 家上市公司的 14,196 条企业一年份观测，系统完成变量设计、企业与年份双向固定效应估计、事件研究、七项稳健性检验、融资约束与竞争异质性诊断，以及 499 次企业政策轨迹置换，形成符合赛题十项规范的完整研究方案与可复现分析材料。结果显示，碳政策暴露与企业绿色发明专利申请呈稳定正向关系，基准系数为 0.0717 ($p=0.00043$)，处理前趋势联合检验 $p=0.494$ ，轨迹置换检验 $p=0.004$ ；独立复算的 16 项核验全部通过。系统将现有结果限定为区域碳政策的支持性复现证据，并为全国碳市场因果命题明确后续数据与识别条件。该案例表明，HypoWeaver-Qwen 已能够将研究问题和证据缺口转化为数据、方法与代码均可落地的社会科学实证研究，并依据数据边界与检验结果调整执行范围和结论强度。

为评价完整 HypoWeaver-Qwen 系统的科研能力，项目构建了包含 10 个绿色金融研究问题的测试集，每题独立运行 3 次，共形成 30 个端到端实验单元。实验结果表明，系统成功形成完整研究方案 29 次，完成率为 96.7%；27 次保持了原研究问题的核心含义，通过率为 90.0%；26 次保持研究主题和限定条件，忠实度为 86.7%；在数据条件不足时，29 次正确停止执行，正确判断率为 96.7%；证据来源多样性检查和异常情况下的安全停止均达到 30/30。多模态实验进一步表明，在系统完成目标表格定位后，Qwen-VL 连续 3 次实现真实科研回归表 47 个字段全部正确，输入量较完整页面处理减少约 65.4%。

关键词：AI Scientist；Qwen；多智能体系统；社会科学实证研究；证据驱动；可复现研究

1 研究背景与项目概述

1.1 从“内容生成”到“实证协同”

最初，大模型进入科研场景主要是承担文献梳理、语言润色、代码补全、知识问答等辅助性工作，并在文本标注等任务上表现出优于众包人工的水平^[1]。这类应用能提高局部环节的效率，但本质上仍是对单项科研任务的自动化：研究问题由人提出，证据由人判断，方法由人选择，结果也主要依靠研究者解释。随着模型推理、工具调用和多智能体协作能力的增强，人工智能开始由“科研助手”走向能够参与科研过程的“AI Scientist”，人工智能驱动的科学发现（AI4Science）已成为系统性的研究方向^[2]。

这一转变已在多个领域得到验证。Coscientist 将大模型与文献检索、实验规划、代码执行和自动化实验设备连接，实现了化学实验的半自主设计与执行^[3]；The AI Scientist 把研究构思、代码编写、实验运行、结果可视化、论文撰写与模拟评审组织为连续流程^[4]；AI co-scientist 通过多智能体间的生成、批判、比较与迭代，围绕科学家设定的目标形成并改进研究假设^[5]。工具层面，ChemCrow、Agent Laboratory、MLGym 等则分别提供了化学工具链、多智能体研究流水线与 AI 科研智能体评测基准^{[6][7][8]}。这些探索表明，AI Scientist 并不是“更会写论文的大模型”，而是一套能够组织证据、提出假设、设计研究、调用工具、检验结果并接受科学审查的科研系统。

然而，现有 AI Scientist 实践主要集中于机器学习、化学和生物学等领域。这些领域通常具有相对明确的实验对象、可执行的计算环境或标准化实验设备，系统可以通过运行代码或操作仪器直接获得新的实验结果。社会科学实证研究的知识生产方式有所不同：研究者通常无法控制政策、制度和个体行为，而需要基于现实世界中已经发生的经济社会现象，利用多来源数据、准自然实验和因果推断识别变量之间的关系^[9]。这种非实验性、强情境依赖的研究特点，决定了社会科学 AI Scientist 不能简单照搬自然科学中的自动实验模式，而需要围绕证据组织、研究设计和因果识别重新构建科研流程。

基于这一领域差异，本项目提出面向社会科学实证研究的 HypoWeaver-Qwen。系统以研究者提出的科学问题为起点，在人的研究目标、学术判断和价值选择约束下，将分散的科研环节组织为可追溯、可执行并可接受审查的研究过程。项目追求的并非无人参与的论文生成，而是让人工智能进入科研过程中耗时、易错且可以规范化验证的环节，成为能够辅助研究设计、执行分析并接受人类审查的智能科研协作者。

1.2 拟解决的关键问题：人工智能科研流程的五处断点

要实现上述系统定位，社会科学领域的 AI Scientist 仍需跨越五类相互耦合的现实障碍。这些障碍分别作用于证据获取、研究命题保持、研究方案执行、统计结论解释和多模态材料利用，并可能沿科研流程逐层传递和放大。

第一，科研证据难以追溯。大模型能够依靠预训练知识快速生成理论解释和文献表述，但模型记忆不能替代经过核验的科研证据。社会科学研究需要综合论文、政策文件、统计年鉴、数据库说明和附录材料等异构资料，并准确区分已有研究发现、理论解释、政策事实、系统推理与待验证假设。如果研究论断缺少明确的来源、原文位置和适用条件，后续假设就可能建立在片面、失真甚至并不存在的证据之上^[10]。

第二，研究问题在长流程中容易发生偏移。社会科学命题对研究对象、变量、分析层级、时间范围和政策情境具有明确约束，多智能体在检索和方案设计中却容易泛化概念、替换变量或改变样本层级。已有研究基于 1600 余条执行轨迹归纳出规格漂移、智能体间错位和验证缺失三类共 14 种失败模式，编码一致性 Kappa 为 0.88；“内容完整但偏离原问题”正是其中的典型表现^[11]。这类偏移会使研究方案表面完备，却无法回答研究者最初提出的科学问题。

第三，研究构想难以转化为可执行的实证方案。列出双重差分、工具变量或断点回归等方法名称，并不等于完成研究设计。经济学实证研究透明度与可复现性综述也将数据来源、变量口径、处理组定义和识别假设列为研究规范的核心内容^[12]。这些要素还需落实到观测单位、时间频率、多源数据匹配和模型设定

中；若数据粒度不一致、关键变量缺失或连接字段不可获得，即使理论构想合理，也无法进入可靠的分析执行与结果复现阶段。

第四，统计结果容易被过度解释。社会科学数据普遍受到选择偏差、遗漏变量、政策实施时点差异和处理前趋势不平等因素影响。回归系数显著并不必然意味着存在因果效应；同样，权威统计学论述明确指出，未达到统计显著性不能直接解释为不存在效应或政策无效^[13]。只有结合识别条件、动态效应、安慰剂检验和稳健性分析，才能判断证据支持何种强度的结论。否则，大模型容易将相关关系表述为因果关系，或在证据不足时给出过于确定的政策判断。

第五，多模态科研证据难以得到可靠利用。社会科学论文中的回归系数、标准误、样本量、模型设定和稳健性结果往往集中在表格、图形及附录中，仅解析正文会遗漏大量关键信息。相关表格检测与结构识别基准也将表头定位、跨列关系恢复等复杂结构列为文档理解的核心难点^[14]。科研表格中这些结构还与脚注、显著性符号和具体数值紧密关联，识别中的字段错位、符号遗漏或数值误读，都可能改变对效应方向、显著性和证据强度的判断。

上述五类断点并非彼此独立。证据失真会影响研究假设，命题偏移会改变变量和样本设定，数据条件不足会削弱识别策略，而统计表格抽取错误又可能导致结论失准。这表明，社会科学 AI Scientist 需要解决的核心问题，不是如何生成形式上更完整的研究文本，而是如何保证证据、命题、研究方案和统计结论在完整科研流程中始终可追溯、可执行、可检验。基于此，下一节进一步明确 HypoWeaver-Qwen 的系统设计目标与主要贡献。

1.3 设计目标与主要贡献

本项目以 Qwen 系列国产大模型为智能底座，构建面向社会科学实证研究的证据驱动型 AI Scientist。系统以研究者提出的科学问题为起点，在保留人工最终决策权的前提下，贯通证据挖掘、假设构建、研究设计、数据适配、统计执行、结果复核与结论审查，目标是形成来源可查、方案可行、结果可信、过程可复现的科研成果。系统评价不以文本流畅度和篇幅为主要依据，而以问题忠实度、证据可追溯性、方案可执行性、结论审慎性、多模态抽取准确性和研究过程可复现性为核心指标。

围绕上述目标，本项目形成三个层面的主要贡献。在研究范式层面，提出面向社会科学实证研究的证据驱动型 AI Scientist 框架，将系统目标由生成研究文本推进到组织、执行和验证实证研究。在技术机制层面，构建证据溯源的假设生成、问题锚定的多智能体协同、研究方案向可执行计量任务转化、识别诊断驱动的结论校准，以及多模态表格证据约束抽取与复核机制。在工程与验证层面，完成基于 Qwen 系列模型的可复现系统实现，并通过系统对照实验、多模态抽取专项实验和真实科研案例，对关键能力及其适用边界进行量化验证，为大模型参与社会科学实证研究提供可落地的技术路径与实践参考。

2 总体解决方案

2.1 系统定位与应用范围

HypoWeaver-Qwen 是面向社会科学实证研究的智能科研工作台。它以研究者提出的问题为起点，以可定位、可核验的文献、政策与数据证据为基础，组织 Qwen 多智能体依次完成假设生成与研究设计、证据提取、执行复核和结论审查，遵循“人提出目标、AI 扩展与执行、程序负责计算、证据决定结论”的分工原则，服务于实证研究全过程，而非单纯生成论文文本。本系统的服务对象按科研流程中的任务定位，可区分出四类用户及其典型任务与系统价值（见表 2-1）。

表 2-1 HypoWeaver-Qwen 的目标用户、典型场景与系统价值

用户类型	典型任务	典型任务	系统价值
需要形成可检验研究方案的 研究者	高校课题组开题、政策课题立项、企业 研究规划、教学案例设计	界定变量与分析层级，选择识别策略， 将数据条件转化为研究设计	将“方法名称”落实为数据口径、处 理组定义与检验路径，减少研究 设计悬空
需要从论文和表格中提取证据 的研究者	文献综述、政策梳理、行业研究与专利 研究	检索与核验文献，抽取表格、图形中的 估计结果，汇总异构证据	将证据追溯至原文位置及其适用 条件，降低错引和数值误读风险
需要执行并复核实证分析的研 究团队	政策评估、ESG 与绿色转型研究、学 术论文复现	开展多源数据匹配、统计分析、稳健性 检验与复现验证	保证分析脚本可复现，使结果解 释与识别条件相匹配，压缩分析 复核周期
需要审查研究论断与证据一致 性的评审者	期刊审稿、课题评审、政策结论复核	核对研究论断与证据强度，识别过度解 释和证据缺口	逐条呈现论断的证据来源与结论 边界，使研究审查由整体通读转 向逐项核验

注：四类用户分别对应科研流程中的方案设计、证据组织、分析执行与结论审查环节，共同覆盖从科学问题提出到研究结论复核的完整科研闭环，并与本项目识别的五处关键流程断点形成对应关系。

2.2 系统基本运行逻辑

HypoWeaver-Qwen 不是将研究问题直接转换为研究报告的单向生成系统，而是围绕社会科学实证研究中的五处关键断点，建立“**问题锚定—阶段生成—结果核验—准入决策**”的基本运行逻辑。系统首先将研究者提出的自然语言问题转化为结构化研究任务，随后依次开展**证据发现、假设构建、研究设计、数据分析和结论审查**。每个阶段均形成明确的中间成果，并检查其是否满足进入下一阶段的条件：检查通过则继续推进，存在偏差则返回修订，关键证据、数据条件或识别假设缺失时则停止执行并说明原因。

表 2-2 HypoWeaver-Qwen 基本运行逻辑

主要作用阶段	对应流程断点	基本运行逻辑
研究启动与全程约束	研究问题在长流程中 发生偏移	先锚定问题，再拓展方案。 明确研究对象、核心变量、分析层级、时间范围和政策情境，并在后续阶段持续检查研究内容与原问题的一致性；出现实质性偏移时返回修订
证据发现与核验	科研证据难以追溯	先核验证据，再形成判断。 将文献观点、政策事实和统计信息关联至具体来源、原文位置及适用条件；无法核验的信息不得直接作为假设和结论的依据
多模态材料处理	表格和图形证据容易 误读	先定位结构，再抽取复核。 先识别目标页面、表格结构和字段关系，再提取变量、系数、标准误、显著性和样本量；发现字段错位或数值冲突时返回原始材料复核
研究设计与执行准备	研究构想难以转化为 可执行方案	先检查条件，再进入执行。 核对数据来源与许可、观测单位、时间频率、变量口径、处理组定义、连接字段及识别假设；条件不足时输出补充清单，不生成虚构结果
统计执行与成果交付	统计结果容易被过度 解释	先审查识别，再解释结果。 结合主回归、动态效应、安慰剂检验、稳健性分析和独立复算判断证据强度，并据此限定结论范围



图 2-1 研究过程

由此，系统形成从科学问题到可验证结论的完整研究过程：**科学问题输入 → 问题结构化与任务规划 → 证据发现与多模态核验 → 科学假设与研究方案生成 → 数据准备与执行判断 → 统计分析与独立复算 → 结论审查与成果交付**。这条流程不是不可逆的线性流水线，而是由阶段准入规则约束的反馈闭环。任一环节未达到要求，任务将返回相关阶段修订；数据、证据或识别条件无法满足时，系统形成明确的停止说明；只有阶段成果通过核验后，才进入下一环节。通过这种运行方式，第一章提出的五处流程断点分别被转化为问题锚定、证据追溯、结构复核、执行准入和结论校准五项控制规则，降低局部错误在科研长流程中持续传递和放大的风险。

3 AI Scientist 系统

3.1 总体架构

HypoWeaver-Qwen 围绕社会科学实证研究任务，构建由**一条科研主线、三层功能架构和一套全流程质量控制机制**组成的 **AI Scientist 系统**。研究者通过工作台提出问题、限定范围并完成关键决策；Qwen 多智能体负责理解任务、组织证据、提出假设、设计方案和开展审查；专业科研工具负责检索、结构化抽取、数据处理、统计估计与独立复算；研究资产与过程状态层统一保存研究问题、证据引用、分析计划、执行结果和审查记录。各层通过结构化研究对象连接，并依据质量控制结果决定继续、修订或停止任务。科研主线为“**问题界定 → 证据核验 → 假设构建 → 实证设计 → 统计分析 → 结果复核 → 成果交付**”；三层功能架构分别是证据基础、专业科研工具和全过程质量控制，从而整个系统得以实现对问题一致性、证据来源、执行条件、统计结果和结论边界的持续检查，如图 3-1 所示。




图 3-1 HypoWeaver-Qwen 总体系统架构

3.2 研究者与成果界面

研究者与成果界面是 HypoWeaver-Qwen 连接科研人员与系统内部流程的统一入口和出口。研究者通过该层提交相关信息，系统则集中呈现结构化研究对象。该层不只是信息展示界面，还承担人机责任边界的落实：研究者在关键节点保留最终决定权，确认后传递至任务编排与审核控制层。

3.2.1 任务输入与结果输出

表 3-1 主要输入与输出

环节	主要输入	主要输出
研究启动	自然语言问题、研究范围、人工约束	结构化研究问题与任务计划
证据发现	论文、政策、数据说明、科研表格	可定位证据、研究图谱、趋势与空白
研究设计	证据束、候选假设、可用数据	十项规范研究计划、数据与识别方案
执行审查	数据资产、变量绑定、统计结果	分析代码、稳健性检验、独立复算
成果交付	审查意见与准入结论	科学结论、研究报告和复现包

3.2.2 关键节点的人工决策

人在回路的设置集中在科研流程中风险最高的五个决策节点，分别对位于前文识别的五处断点。**其一，研究问题确认。**多智能体在检索与机制拓展中容易泛化概念、替换变量、改变分析层级，导致流程漂移；研究者在此节点锁定问题的边界与约束，作为后续所有环节的基准。**其二，候选假设选择。**系统可以生成大量备选假设，但假设的理论价值、与证据的匹配程度以及检验成本，须由研究者裁决——哪些假设值得投入数据与算力，属于科学判断而非生成任务。**其三，数据使用授权。**数据涉及隐私、使用许可与合规要求，任何数据源的接入、匹配与分析都必须经过人工授权，这是研究伦理的硬约束，不设自动化豁免。**其四，分析方案确认。**识别策略、变量口径、样本范围、处理组定义与检验路径，在进入代码执行前由研究者最终确认，防止“方法名称齐全、设计细节悬空”。**其五，最终结论确认。**统计结果向研究结论的转化由研究者把守：效应方向、证据强度与政策含义的表述须经人工复核，防止相关误作因果、证据强度被夸大。在上述节点，系统负责扩大检索范围、提出备选方案并暴露潜在风险，研究者保留目标设定、伦理判断与成果发布权。自动化提升科研效率，科学责任始终由人承担。

3.3 任务编排与审核控制

任务编排与审核控制层是 HypoWeaver-Qwen 的流程中枢，负责将研究者提出的自然语言需求转化为可管理、可检查的结构化研究任务。该层维护原始研究问题、任务依赖关系、阶段状态和调用预算，并根据研究进度调度科研智能体与专业科研工具。同时承担全过程审核控制，但不代替科研智能体完成具体的证据综合和研究判断。

3.3.1 问题锚定

系统将原问题拆解为研究对象、暴露因素、结果变量和限定条件，作为贯穿全流程的稳定上下文。每轮规划后重新比较候选问题与原问题；若核心要素被替换，系统携带缺失概念重新检索，而不是直接进入最终生成。

3.3.2 修订闭环

审查者输出的缺失概念、问题偏移原因与检索建议被结构化写入下一轮 Planner 上下文，并以哈希记录保证反馈可追溯。审查意见由此成为可执行输入，而非生成完成后附加的一段无法改变方案的评价，从而形成真正的“审查—修订”闭环。修订次数受调用预算约束，若关键问题在预算内仍未解决，系统停止后续执行并保留失败原因，不以新文本掩盖问题。

3.3.3 结论分级

系统把候选结论与所需检验逐项对应：证据支持且识别条件成立时允许相应强度的表述；存在反对证据时降级为混合或条件性结论；证据无效、引用未知或关键检验缺失时禁止因果表述。该过程由确定性规则编译，不依赖模型再次自由判断。

3.4 科研智能体协作

科研智能体协作层是 HypoWeaver-Qwen 的智能执行核心，承载科研流程中的语义理解、证据整合、方案生成与质量审查功能。系统基于角色专责、流程协同、结果校验的设计原则，设置五类定位清晰、权责边界明确的科研智能体，通过标准化协作机制与上下文工程，形成 “问题拆解→证据溯源→研究设计→质量审查→成果输出” 的闭环智能科研链路。其中 Qwen 系列模型为各智能体提供语义理解与文本生成能力支撑，是实现科研任务垂直化、专业化处理的核心基础。

在协作过程中，Qwen 文本模型承担全流程的语义处理职能：将自然语言研究需求解析为结构化问题框架，基于来源约束的文献证据形成理论推演，构建可证伪假设与作用机制，将研究假设转化为数据与方法需求，开展研究方案与原问题的一致性校验，并在统计执行完成后依据证据状态解释研究结果。Qwen 视觉模型则定向承担科研表格、统计图表等多模态材料的信息提取与结构理解。需要明确的是，模型生成的所有方案、推论与抽取结果均需经过结构化校验、来源核验或确定性程序复核；Qwen 模型不直接计算回归系数、不判定统计显著性，也不替代研究者作出最终科学判断。

3.4.1 多智能体的构成与分工

表 3-2 智能体分工

智能体角色	核心职责	主要交付
文献与证据研究者	多源文献检索、来源核验、向量库构建、基于 Qwen 的实体抽取与知识图谱构建	结构化证据束、领域研究知识图谱
科学假设设计者	基于 Qwen 理解文献证据与作用机制、识别研究空白、生成候选研究假设	理论机制推演、可证伪候选假设集
数据与方法专家	研究方法筛选、数据资源检索匹配、变量设计、识别策略与检验方案构建	可选研究方法集、数据变量字典、研究执行计划、分析执行结果
质量审查者	数据质量审查、结果复现校验、研究问题偏移识别、基于 Qwen 的问题分析与审查意见生成	问题清单、修订意见与改进方向
文献撰写者	研究成果整理、垂直领域学术论文初稿撰写	结果汇总表、可复现材料包、学术论文初稿

3.4.2 多智能体间的协作原理

多智能体协作机制是 HypoWeaver-Qwen 系统科研流程高效、稳定运行的核心支撑。本系统以权责清晰、目标统一、衔接有序、成果可控为基本原则，构建角色化上下文构建、任务分解与调度、成果类型化与交接的协同机制，保障五类科研智能体在长周期研究任务中实现稳定协同。协作机制的设计融合提示工程方法体系：上下文构建机制明确各智能体的任务边界与语义基准，任务调度机制保障研究流程的逻辑次序与执行效率，成果交接机制实现智能体间工作成果的可靠传递与质量管控。

（1）角色化上下文构建：基于分工与连贯双重目标的提示工程设计

多智能体协作的有效性，首先取决于各智能体对自身职责的准确认知，以及任务接力过程中整体研究目标的一致性。本系统将角色化上下文构建视为提示工程在科研流程中的工程化应用，围绕权责边界清晰与跨环节语义连贯两大核心目标展开设计。

针对明晰全责边界，系统为每一类科研智能体构建独立的角色专属上下文，其内容采用五要素结构化范式：角色身份与职能定位、领域知识与专业约束、任务输入规范、输出格式标准、行为边界限定（如禁止自行生成统计数值、禁止跨环节替代其他主体决策）。通过角色提示（Role Prompting）与结构化提示词模板，将各类智能体的输出严格约束在自身职能边界之内，从上下文输入层面规避权责混淆与越权生成。例如，文献与证据研究者的上下文限定其核心职能为证据检索、来源核验与知识图谱构建，不涉及研究方案的设计与推导；质量审查者的上下文则遵循 “审查独立、不参与生成” 原则，保障审查结论的客观性与中立性。

科研活动是具有连续逻辑的系统性过程，各智能体虽分工不同，但必须围绕同一研究命题、基于同一证据基础开展协同工作。系统从三个维度在上下文设计中保障语义连贯性：一是公共问题锚定，将研究者输入的原始问题经结构化解析后形成核心要素集（研究对象、解释变量、结果变量、分析层级、时间范围），嵌入每一类智能体的上下文作为全流程不可偏移的公共基准；二是成果摘要衔接，智能体承接任务时，仅接收上一环节输出的关键结论摘要而非全量对话历史，在控制信息冗余的同时，保障前序研究结论在后续环节的准确继承；三是引用链条传递，各环节所引用的证据、变量与结论均携带唯一来源标识，随上下文同步传递，保障全流程研究论述始终可追溯、可核验。

（2）任务分解与调度：串行主链、并行分支与门控保障

系统依据社会科学实证研究“证据支撑假设、假设决定方法、方法驱动执行、执行接受审查”的内在逻辑依赖关系对任务进行层级分解，遵循先串行主链、后并行分支、门控机制兜底的调度逻辑，兼顾研究流程的严谨性与执行效率。

串行主链路严格遵循实证研究的逻辑次序，五类智能体逐阶交接、依次推进：文献与证据研究者完成证据检索与知识图谱构建后，将标准化证据成果移交科学假设设计者；假设设计者完成理论机制推演与候选假设生成后，将可证伪假设集移交数据与方法专家；数据与方法专家形成数据方案与识别策略并产出分析结果后，移交质量审查者开展全维度校验；审查通过后最终由文献撰写者完成成果汇总与论文撰写。各环节均以上游成果通过校验为启动前提，形成环环相扣的研究链路，从流程结构上规避逻辑倒置与环节缺失。

专业工具协同调度将文献检索、知识图谱构建、统计执行、独立复算等专业工具嵌入对应研究环节，由调度层统一管理调用；工具的输入与输出均以标准化成果对象为载体，实现智能体语义推理能力与确定性计算能力的解耦与协同，避免语义模型直接参与数值计算。

并行分支针对多源文献检索、多主题假设推演、多识别策略评估、多维度质量审查、多组稳健性检验等无前置依赖的子任务采用并行调度模式，结果在预设汇合点统一汇入串行主链并接受准入校验，在不破坏主链路逻辑顺序的前提下，充分释放算力与任务并行潜力，压缩整体研究周期。

阶段门控与异常回退设置阶段准入校验机制，防止局部错误沿科研流程逐级传递放大；执行失败的任务标记问题属性后回退至对应上游环节修订，形成“校验—反馈—修订”的闭环迭代；同一环节修订次数达到设定阈值仍未通过时，流程自动暂停并提请研究者人工介入，始终保留研究者的最终科研决策权。

（3）成果类型化与交接：标准化契约驱动的可靠传递

成果类型化是多智能体高效可靠协作的接口基础，系统通过梳理各环节核心交付物、定义统一结构化模式与数据契约、注册统一交互标准三步法构建标准化成果类型体系，将智能体交互从自由文本对话转化为结构化对象传递；严格以 3.4.1 节职能分工为基准，文献与证据研究者输出含来源标识、类型标签与适用边界的结构化证据束及领域知识图谱，科学假设设计者输出含变量定义、机制说明与可证伪条件的理论机制推演结论及候选假设集，数据与方法专家输出含识别策略、变量构造与统计结果的方法集、变量字典、执行计划与分析结果，质量审查者输出分级问题清单与修订意见，文献撰写者输出结果汇总表、可复现材料包与学术论文初稿；同时设置字段完整性、逻辑一致性、来源可追溯性三重校验，构建前端约束、后端校验、异常处理三层防控体系，校验记录全程留痕，保障信息传递精准性与研究过程可复现性。

3.5 专业科研工具

专业科研工具层将科研智能体提出的检索、抽取、数据处理和统计分析要求，转换为可重复执行、可确定性检查的程序操作。工具链覆盖证据获取、数据适配、分析执行与结果验证四个阶段。其输出内容一方面返回科研智能体进行解释和审查，另一方面写入证据、数据与过程记录层。

3.5.1 多来源证据检索与追溯

第一，协同检索机制。知识底座已处理 1,169 份文档，形成 19,567 个文本块与向量。系统同时使用关键词匹配、语义向量和研究图谱关系召回证据：关键词保证政策名称和专业术语准确命中，向量检索发现同义表达，图谱则沿变量、机制、方法与结论关系扩展候选证据。

第二，来源追踪与多样性控制。每个证据片段绑定文档、章节、原文位置和内容哈希。排序后设置单篇文献的片段上限，避免多个高分片段实际来自同一论文；系统同时记录命中片段数、独立文献数和被跳过片段数，使“多项证据”确实对应多个独立来源。

第三，“论断—证据”绑定与引用约束。系统将文献明确报告的结果、跨文献综合得到的推论和待验证假设分别标注。最终研究计划只能引用当前证据束中存在的来源标识，引用越界会触发重新生成；对于趋势和研究空白，表述范围限定在已检索语料和检索日期内。

3.5.2 科研多模态信息抽取与复核

第一步，页面和表格定位。系统先利用论文目录、正文引用和版面坐标定位目标表格，再裁切出最小充分图像，降低相邻表格、页眉、脚注和双栏文字对识别的干扰。

第二步，约束抽取。Qwen-VL 按预定义字段提取表题、模型列、变量名、系数、标准误、显著性、样本量和固定效应，并输出结构化 JSON。模型不得补写空白单元格，也不得把脚注说明当作统计结果。

第三步，字段、结构和数值复核。抽取后逐字段比较数值、符号、显著性和空值，检查列数、路径和字段完整性。真实实验表明，整页条件的数值虽全部正确，但稳定漏判一个显著性星号；目标表裁切后连续三次达到 47/47 字段全对。

3.5.3 数据适配与执行准入

系统将研究计划中的必需输入条件（required inputs）编译为数据资产清单、变量字典和识别策略配置，并据此判断研究任务是否具备执行条件。该机制按照“数据资产核验—变量字段绑定—执行准入决策”的顺序运行，防止研究方案建立在无法取得、无法匹配或无法复核的数据之上。

第一步，数据合规性与准备状态检查。系统核验候选数据资产的可用性。每个候选数据集均需记录文件名与存储位置、使用许可、文件哈希、文件大小、观测粒度、时间键和连接键。许可状态未知、资产无法定位或文件哈希缺失的数据不得直接进入执行；观测粒度、时间范围或连接关系不满足研究要求的数据，则被标记为待补充或待转换资产。

第二步，研究变量与数据字段绑定。系统将理论构念编译为变量字典，把解释变量、结果变量、中介变量和调节变量绑定到具体数据字段，并检查字段含义、数据类型、时间频率和观测层级是否与研究设计一致。无法找到对应字段或无法完成可靠构造的理论构念，不进入统计模型，而是转化为明确的数据缺口与补充任务。

第三步，识别策略、成立条件与失效风险。方法专家不仅给出模型名称，还必须说明比较对象、处理时间、固定效应、聚类层级、识别假设和诊断方法。双重差分方案必须包含处理前趋势和处理组规模检查，机制与异质性分析也需预先定义边界。识别假设不成立、诊断检验未通过时，任务转入修订或停止流程（见 3.3.2），而不是继续执行。

第四步，执行门控与安全停止。系统综合数据资产核验、变量字段绑定和识别策略配置结果形成执行准入判断。只有数据许可与文件身份可核验，观测粒度、时间键和连接键满足匹配要求，核心变量完成字段绑定，识别策略具备必要数据条件时，系统才生成并运行统计分析代码；否则停止执行，输出具体阻塞原因及补充清单。系统能力实验中的确定性正反对照进一步检验该机制能否在条件缺失时正确阻断任务，并在条件完整时正常放行。

3.5.4 统计执行与独立复核

Qwen 负责形成分析计划和解释结果，Python 统计引擎依据冻结方案执行估计、事件研究、置换与稳健性检验。复核者使用另一套实现重新计算核心系数、样本量和诊断，并比较允许误差；报告中的数字只从执行结果和复算记录读取，避免由模型口述或人工转抄产生误差。

3.5.5 Qwen 与专业科研工具的职责边界

表 3-3 Qwen 与科研工具的职责边界

能力主体	负责内容	不承担内容
Qwen 文本/视觉模型	问题理解、证据综合、假设与方案、审查解释、表格抽取	不直接决定统计真值，不凭记忆替代证据
确定性程序工具	检索约束、结构校验、统计估计、复算、哈希与准入规则	不替代研究者的价值判断与问题选择
研究者	确定问题、范围、数据授权和最终研究判断	无需手工重复所有检索、计算与格式整理

3.6 证据、数据与过程记录

证据、数据与过程记录层是 HypoWeaver-Qwen 的研究资产基础，负责统一保存科研过程中使用的原始材料、形成的结构化研究对象以及产生的执行记录。该层不参与研究内容生成，而是为科研智能体和专业工具提供可定位、可关联、可回溯的研究材料，使科学结论能够追溯至原始证据和实际执行过程。

3.6.1 原始资料与可定位证据管理

系统统一登记论文、政策文件、统计资料、数据库说明、科研表格和实证数据等原始资产，并记录文件位置、来源信息、许可状态、文件哈希和版本标识。文献与证据研究者从原始资料中提取研究论断、政策事实、变量定义和统计结果时，同时保留原文位置、适用条件及其与研究问题的关系，形成可定位证据。

原始资料与提取证据分开保存：前者作为不可替代的来源依据，后者作为智能体可以检索、组合和审查的结构化研究对象。任何进入假设构建和结论审查的证据，均可反向定位至对应的原始材料，避免文献表述与真实来源脱离。

3.6.2 研究问题、假设与分析结果记录

系统将研究过程中的关键中间成果保存为结构化研究对象，包括原始研究问题、问题约束、证据束、研究图谱、候选假设、变量字典、数据需求、识别策略、分析计划和审查意见——该目录是各层协作对象的统一定义。不同智能体围绕这些对象开展协作，从而减少角色交接过程中的信息遗漏和含义偏移。

当研究问题、假设或分析方案发生修改时，系统保留修改前后的版本、修改原因、提出修改的角色以及相应审核结果，并同步更新任务状态。由此可以还原研究方案从提出、审查到修订的演化过程，也可以检查最终分析是否仍然对应研究者最初提出的科学问题。

3.6.3 过程留痕与可复现成果管理

进入执行阶段后，系统记录数据文件、变量绑定、分析代码、运行参数、统计结果、稳健性检验、独立复算结果和异常信息，并建立分析计划、执行代码与结果文件之间的对应关系。若任务因数据缺失、识别条件不成立或复算结果不一致而停止，系统同样保存阻塞原因和补充要求。

任务完成后，系统将通过审核的证据、研究方案、分析代码、结果表、诊断报告、审查意见和最终报告整理为统一的复现材料包。研究者既可以核查结论所依据的证据与计算过程，也可以基于保存的数据、代码和配置重新执行分析。

3.7 端到端运行闭环

一次完整任务形成可追踪的状态链：原问题被结构化后进入证据检索，候选证据生成研究图谱与假设，数据与方法专家形成执行计划，审查者给出准入或修订决定；通过执行准备检查后运行分析与复算，最终由结论审查生成与证据强度匹配的报告。所有阶段产物均写入同一研究任务目录。

4 代表性科研案例：反馈驱动的两轮实证研究闭环

4.1 案例介绍

4.1.1 案例选择与初始研究条件

系统对绿色金融文献与政策资料的研究图谱分析显示，相关研究正由融资规模、绿色创新数量等中间结果，进一步转向真实环境绩效与创新质量。据此，本案例以“**碳市场约束是否促进企业高质量绿色创新**”为科学问题，目标是形成并验证一条**可执行、可迭代的实证任务链**——从问题界定、证据检索、数据绑定、统计执行、反馈调整直至独立复算的完整闭环。

选择该案例的依据有三：其一，问题同时覆盖证据检索、数据绑定、统计执行、反馈调整和独立复算，能够检验系统全链路能力；其二，可集中展示 Qwen 规划、执行就绪审计、两轮协议冻结、质量控制与结论准入等关键机制；其三，该案例并非筛选出的“最顺利个案”——第一轮执行真实触发两个硬阻断条件，第二轮方案由反馈机制产生，恰好呈现系统在条件不足时正确停止、经修订后重新收敛的过程。需要说明的是，本案例代表社会科学计算实验的一般形态，不涉及物理仪器控制；系统当前的任务是判断全国碳市场命题是否具备数据与识别条件，而非直接识别全国碳市场效应。案例初始条件如表 4.1 所示。

表 4-1 案例基本情况

内容	本案例实际情况
已有证据或初始数据	12 个证据片段、7 篇文献；2 个 CC BY 4.0 候选数据源；原问题为全国碳市场与高质量绿色创新。
实验对象、仪器或仿真条件	上市公司—年度面板；Qwen3.7-plus、检索与审计模块、Python 统计执行器、独立复算器。
可控变量与主要约束	核心字段为政策暴露、绿色发明、规模、杠杆率和 ROA；要求许可清晰、主键完整、结果期充分。
第一轮希望获得的观测结果	判断全国命题是否具备数据与识别条件；若不具备，定位可执行的替代研究范围。
第一轮评价方法	证据多样性与计划一致性；许可、哈希、时间覆盖、官方名单绑定和处理路径完整性。

4.1.2 理论机制与可证伪假设

碳价、排放配额与履约约束会提高高排放技术的相对成本，并可能诱导企业调整创新方向；已有环境规制与诱导创新研究为这一价格—技术替代逻辑提供了理论和经验基础^{[15][16][17]}。但新增合规成本也可能挤占研发预算，企业还可能以低质量专利替代实质性创新，因此政策影响需要由企业层面数据检验，不能由理论预设。

系统据此形成三组可证伪假设：H1 检验政策暴露是否提高绿色发明专利申请；H2 检验融资条件改善是否与政策作用路径一致，融资约束采用 SA 指数相关口径^[18]；H3 检验市场竞争是否改变政策效应。三组假设分别对应主效应、机制诊断与边界条件，并允许出现不支持预设的结果。




图 4-1 碳市场影响企业高质量绿色创新的理论机制

注：实线表示价格与规制、金融资源两条主要路径，虚线表示待检验的竞争边界条件。该图用于组织变量与假设，不预先替代统计结论。资料来源：HypoWeaver-Qwen 根据冻结证据包生成。

表 4-2 研究假设与本轮检验状态

假设	可证伪表述	本轮检验状态
H1	碳政策暴露提高企业绿色发明专利申请	区域复现支持：β=0.0717，p=0.00043
H2	融资条件改善是政策影响高质量绿色创新的重要路径	融资约束代理值下降；仅作机制一致性诊断
H3	政策效应随市场竞争程度变化	交互项 p=0.117，当前样本未提供统计支持

4.2 第一轮研究计划：全国碳市场命题的执行可行性审查

第一轮研究的目标不是直接估计全国碳市场对企业绿色创新的影响，而是判断该命题能否在现有证据与数据条件下转化为可执行、可复核的实证研究。系统首先综合相关文献并明确理论机制、变量关系和数据需求，随后审计候选数据的许可、结构与处理组织识别条件，在此基础上作出全国范围的执行准入判断。若全国命题暂不具备执行条件，则按照预先设定的规则缩小研究范围；研究协议在读取结果变量并开展模型估计之前冻结，避免依据统计结果反向调整问题、样本或识别策略。

4.2.1 全国研究命题与最低证据要求

本轮以“全国碳市场能否促进企业绿色创新”为待验证命题。系统基于本地知识库快照开展证据检索与综合，共调用 Qwen3.7-plus 两次，耗时 78.25 秒；检索参数设为 top-k=12，每篇文献最多保留 2 个证据片段。最终纳入 7 篇文献的 12 个证据片段，用于梳理政策影响绿色创新的机制链、核心变量及数据需求。

证据筛选同时检查来源多样性及其与原研究问题的一致性。如果证据集中于单一来源，或者检索结果偏离全国碳市场、企业绿色创新等核心研究对象，系统不进入数据设计阶段，而是调整检索条件并重新获取证据。

两次 Qwen3.7-plus 在线调用分别用于研究规划和问题一计划一致性审查，共使用 17,178 个输入 tokens 和 4,260 个输出 tokens，端到端耗时 78.25 秒，未发生失败或修复。最终证据包保留 7 篇文献的 12 个片段，每篇最多 2 个片段，并跳过 35 个同文献冗余命中；模型不直接生成回归系数，也不决定显著性阈值。

表 4-3 千问真实调用记录

指标	实际记录	说明
模型	Qwen3.7-plus	阿里云百炼在线调用
调用次数	2 次	研究规划 1 次，一致性审查 1 次
输入 tokens	17,178	仅发送冻结问题与授权文献片段

指标	实际记录	说明
输出 tokens	4,260	结构化研究计划与审查结果
端到端模型耗时	78.25 秒	两次调用合计
失败与修复	0 次 / 0 次	调用合同与结构校验均一次通过
匿名回执	已保存	记录模型、时间、哈希与 token 统计，不含 API Key

4.2.2 候选数据审计与执行准入条件

在证据综合的基础上，系统将研究命题转换为可检查的数据需求，并对两个公开候选数据集开展许可与完整性审计。审计内容包括数据许可、资产位置、SHA-256 哈希、时间范围、字段结构、企业一年份主键、结果变量、政策处理字段以及多源数据连接路径。

两个候选数据源均采用 CC BY 4.0 许可：企业碳信息披露与绿色创新补充数据因缺少可稳定连接的企业一年份键而仅保留为后续机制资料^[19]；Industry Peer Effect of Corporate Green Innovation 数据包含 2010—2021 年企业面板、政策暴露、绿色专利和财务字段，因而进入区域碳政策公开复现^[20]。

表 4-4 两个公开数据候选及审查决策

数据候选	许可与标识	审查结果	系统决策
企业碳信息披露、融资约束与绿色创新补充数据	CC BY 4.0; DOI 10.1371/journal.pone.0319997.s001	四个工作簿缺少可稳定连接的企业一年份键	保留为后续机制数据，不进入本轮估计
Industry Peer Effect of Corporate Green Innovation 数据	CC BY 4.0; DOI 10.17632/rrfwyny7byp.1	含 2010—2021 年企业面板、政策暴露、绿色专利和财务字段	进入区域碳政策公开复现

全国范围的政策效应估计必须同时满足以下条件：能够获得 2021 年后的企业绿色创新结果数据；能够依据官方名单识别碳市场覆盖企业；企业与年份主键完整且唯一；结果变量和政策处理变量可以稳定构造；不同数据源之间存在可复核的匹配路径。上述条件均通过后，系统才作出“可执行（Go）”判断；任一硬性条件缺失，则作出“暂不执行（No-Go）”判断，不估计全国范围的政策效应。

4.2.3 替代研究范围与协议冻结

为避免全国命题因数据不足而直接中断，系统在结果读取前预设区域层面的替代研究范围。替代方案使用 2010—2021 年面板数据及原始政策字段，但只有在区域标识、结果变量、时间跨度和政策处理路径完整时才能启动。若替代范围仍不满足执行条件，系统停止自动分析并转交研究者决定是否补充数据或重新界定问题。

第一轮研究协议在读取结果变量和拟合模型之前冻结，并与输入数据哈希绑定。人工仅负责确认文献片段和数据可以用于本次百炼调用，以及核对系统给出的研究边界，不根据后续统计结果修改样本范围、识别策略或准入阈值。因此，本轮只完成证据综合、数据审计和执行准入判断，不拟合企业绿色创新结果模型。

表 4-5 第一轮全国碳市场研究命题的执行可行性审查方案

决策阶段	输入与主要参数	核心检查或动作	阶段输出	未通过时的处理
研究命题与证据编译	全国碳市场研究问题：7 篇文献、12 个证据片段；Qwen3.7-plus; top-k=12; 每篇文献不超过 2 个片段	综合理论与实证证据，检查来源多样性及其与原问题的一致性	结构化研究问题、机制链、变量关系和数据需求	调整检索条件并重新获取证据

决策阶段	输入与主要参数	核心检查或动作	阶段输出	未通过时的处理
候选数据	2 个公开候选数据集；	检查许可、资产位置、时间范围、字段	数据血缘、字段字典及主	许可、哈希或关键字段不完整
审计	SHA-256 校验	结构、主键和数据连接路径	键清单	的数据不得进入执行
全国范围	2021 年后结果数据、官方覆盖	以确定性规则检查结果变量、处理组织	全国研究命题的	任一硬性条件缺失时不估计全
准入	企业名单及企业—年份主键	别和数据匹配条件	Go/No-Go 结论	国效应
替代范围	原始政策字段；2010—2021 年	检查区域字段、结果变量、时间跨度和	第二轮研究范围、方法与	替代范围仍不可执行时转交人
判断	区域面板	政策处理路径	停止规则	工决策
研究协议	研究问题、数据哈希、变量定	在读取结果和模型估计前固定研究范	可追踪、可复核的冻结协	禁止依据统计结果事后修改范
冻结	义及准入规则	围与判断标准	议	围或阈值

4.3 第一轮执行结果：全国命题阻断与替代范围准入

第一轮按照预先冻结的研究协议，依次开展证据质量检查、数据资产审计和执行条件判断。结果显示，证据与研究计划的一致性、候选数据的许可及结构完整性均通过检查，但全国碳市场命题因缺少 2021 年后的结果数据和官方履约企业名单绑定而触发硬阻断。系统因此未拟合全国范围的政策效应，而是按照预置规则转入区域替代范围审查。区域数据通过基本准入检查，但暴露状态存在非单调变化，需要在后续事件研究中进行专门处理。

4.3.1 逐阶段执行与审计结果

表 4-6 第一轮执行的过程记录与阶段结果

项目	证据与数据基础检查	数据资产与结构审计	国碳市场命题的硬阻断	区域替代范围的可执行性确认
实际动作	Qwen 证据门：2 次真实调	许可、哈希、模式与主键	全国市场执行就绪检查	区域复制范围与路径审计
与参数	用	审计		
获得的原始结果	12 个片段、7 篇文献；17,178 输入/4,260 输出 tokens	2 个候选数据源：原文件 与分析抽取哈希	数据仅至 2021 年；官方履约企业名单 未绑定	14,208 条、1,184 家企业；75 家存 在 1→0 回退
质量检查	多样性门和问题—计划—致性均通过	CC BY 4.0；企业—年份无 重复	触发 2 项硬阻断	区域复制可执行；事件研究需处理 回退路径
与预期的差异	达到预期	达到预期	未达到预期	形成替代路径
耗时或资源	78.25 秒；无失败或修复	Python 审计器；本地执行	确定性规则；未拟合结果	本地审计；生成 Round 1 回执

表 4-7 执行就绪审查与路线选择

审查门	全国市场路线	区域复现路线
结果期	未通过：数据止于 2021 年	通过：可研究 2010—2021 年源定义区域暴露
处理组来源	未通过：缺少官方履约企业名单绑定	通过：使用发布者提供的企业—年份政策编码
企业—年份键	通过	通过
创新与融资字段	通过	通过

审查门	全国市场路线	区域复现路线
执行决定	保留为后续确认性研究	进入第二轮冻结与统计执行

第一轮的产生不是一个政策系数，而是两条具有不同证据状态的研究路线：当前数据用于形成可复现、可核验的区域证据；全国市场命题则携带 2022 年以后结果数据和官方履约名单等补充清单进入后续确认。该决策顺序避免先运行回归、再解释数据是否适用。

4.3.2 第一轮实际评价

第一轮评价不以是否得到政策效应为唯一标准，而是分别考察证据质量、全国命题就绪度和区域替代方案就绪度。评价结果表明，证据基础达到预期，全国命题因两项关键数据条件缺失未获准执行，区域替代方案则在明确非单调处理路径风险的前提下获得有条件准入。

表 4-8 第一轮结果评价

实际评价内容	评价口径	第一轮结果	是否达到预期	不确定性或误差
证据质量	7 篇文献；每篇≤2 片段；计划一致性	通过	是	跳过 35 个同文献冗余命中
全国命题就绪度	结果期与官方名单两项硬门	不通过	否	缺少 2021 年后结果和官方名单绑定
区域复制就绪度	许可、主键、变量、样本和路径	通过	是	源定义暴露及非单调路径需限定处理

第一轮没有回避未达预期的全国命题；该结果被原样保存，并直接成为第二轮范围调整的输入。

4.4 第二轮：调整后的区域实证研究

第二轮采用双向固定效应和事件研究，并针对第一轮识别出的处理路径问题进行诊断。区域问题完成真实执行；采用 2010—2021 源定义暴露面板后，第二轮实际样本为 14,196 条观测、1,183 家企业。

4.4.1 实验计划演变

表 4-9 实验计划演变

变化内容	第一轮	第二轮	变化原因
任务内容与顺序	全国市场效应识别	先执行区域复制，再保留全国确认任务	全国范围存在硬阻断
参数与实验条件	需官方名单和 2021 年后结果	2010—2021 源定义暴露面板	采用当前可验证范围
数据获取方式	计划绑定官方名单与新增年度	使用 CC BY 4.0 公开面板与最小抽取	保证当前轮可复现
分析与判断方法	全国 DID 候选设计	双向固定效应、事件研究、7 项稳健性、499 次置换、独立复算	处理路径和结论边界需要加强
停止或继续条件	全国硬门不通过即停止	区域支持标准+主张准入门	区分当前证据与未来确认

表 4-10 第二轮冻结分析合同

要素	冻结定义
研究样本	2010—2021 年 1,183 家上市公司，14,196 条企业—年份观测；12 期平衡面板
政策暴露	发布者提供的企业—年份政策暴露编码；946 家企业曾暴露，237 家从未暴露
主结果	$\ln(1 + \text{绿色发明专利独立申请} + \text{绿色发明专利联合申请})$
对照结果	独立绿色发明、全部绿色专利、绿色实用新型专利

要素	冻结定义
控制变量	企业总资产对数、资产负债率、资产收益率
固定效应	企业固定效应与年份固定效应
统计推断	标准误按企业聚类；识别同一企业内部政策暴露变化与创新变化的条件关联
事件研究	仅保留政策路径单调企业，以首次暴露前一年为基期，合并远端提前期和滞后期

第二轮在第一轮结果形成不可变哈希后冻结。主结果、控制变量、样本排除、固定效应、聚类层级、事件窗口、替代结果和置换次数均在读取估计结果前确定。若结果缺失导致样本键不唯一、事件研究不存在有效基期、置换分布无法复算，或者独立估计器与主执行结果不一致，系统停止结论生成。双向固定效应模型估计企业内部变化，事件研究用于检查处理前趋势和政策后的动态形态；鉴于首次暴露时间不同，传统事件研究不单独授权全国市场因果结论。

表 4-11 碳市场案例十项实验矩阵

序号	实验	核心设定	测试的系统能力
1	证据发现	千问读取多来源全文片段，形成研究空白与假设	证据驱动的问题生成
2	数据执行门	审查许可、哈希、键、结果期和政策名单	问题与数据匹配
3	基准模型	企业和年份固定效应、三项控制、企业聚类	计划到统计代码的编译
4	动态效应	单调路径样本，以首次暴露前一年为基期	前趋势和响应路径诊断
5	稳健性	无控制、剔除 2021 年、单调路径、替代结果等	识别对单一设定的依赖
6	创新质量区分	发明专利与实用新型专利对照	区分创新质量与数量扩张
7	融资约束诊断	以 SA 指数绝对值为结果变量	理论机制与数据模式对照
8	竞争异质性	政策暴露与高竞争行业交互	边界条件的正反结果报告
9	轨迹置换	499 次企业完整暴露路径随机交换	随机参照分布与异常性检验
10	独立复算与结论准入	独立估计器、哈希核对、表述分层	结果复现与结论强度控制

十项实验依次检验四层能力：能否提出有证据的问题，能否找到与问题匹配且可执行的数据，能否按冻结计划完成真实统计，以及能否独立复算结果并限制结论强度。评价对象是完整 AI Scientist 系统，Qwen 的语言推理是其中的规划与审查环节，而非全部系统能力。

4.4.2 稳健性、置换检验与独立复算

第二轮在区域公开复现中加入 7 项稳健性、499 次轨迹置换和独立复算；源文件、最小抽取和第二轮协议哈希封存。区域复制 16/16 复算通过。

第二轮冻结样本包含 2010—2021 年 1,183 家上市公司的 14,196 条企业一年份观测，其中 946 家企业曾暴露、237 家从未暴露。主结果为 $\ln(1+\text{绿色发明专利独立申请}+\text{联合申请})$ ，控制变量包括企业总资产对数、资产负债率和资产收益率；模型设置企业固定效应与年份固定效应，标准误按企业聚类。事件研究仅保留政策路径单调的企业，并以首次暴露前一年为基期。考虑到处理时点不同，双向固定效应和传统事件研究的解释需结合分期处理偏误研究进行限定^{[21][22]}。

表 4-12 区域复现的基准模型与稳健性结果

模型	系数	聚类 SE	p 值	95%置信区间	观测数
基准模型	0.0717	0.0204	0.00043	[0.0318, 0.1117]	14,196
不含控制变量	0.0729	0.0204	0.00035	[0.0330, 0.1129]	14,196
剔除 2021 年	0.0737	0.0196	0.00017	[0.0353, 0.1121]	13,013
仅单调暴露路径	0.0805	0.0223	0.00031	[0.0368, 0.1242]	13,296
仅独立绿色发明	0.0627	0.0152	<0.0001	[0.0328, 0.0925]	14,196
全部绿色专利	0.0602	0.0240	0.0123	[0.0131, 0.1073]	14,196

模型	系数	聚类 SE	p 值	95%置信区间	观测数
实用新型对照	0.0229	0.0182	0.2083	[-0.0128, 0.0585]	14,196
加入行业集中度	0.0722	0.0205	0.00042	[0.0321, 0.1124]	14,089

基准系数 0.0717 对应约 7.4%的对数点变化。剔除 2021 年、排除非单调暴露路径以及更换绿色专利口径后，核心估计方向保持为正；实用新型专利系数较小且不显著，说明结果更集中于发明专利所代表的高质量绿色创新。




图 4-2 不同模型中的政策暴露系数

注：圆点为政策暴露系数，横线为企业层面聚类的 95%置信区间，虚线为零。资料来源：Mendeley Data 公开复现样本，HypoWeaver-Qwen 统计执行。




图 4-3 政策暴露前后的绿色发明专利动态

注：-1 期为基期，仅使用政策路径单调的企业。处理前“≤-4、-3、-2”期联合检验 $p=0.494$ ，未拒绝平行趋势；暴露后第 1—3 期系数依次为 0.0661、0.0873 和 0.1005。该动态证据用于限定区域复现的可信度，不授权全国市场因果外推。

499 次企业完整暴露轨迹置换得到零分布均值 0.00026、双侧 $p=0.004$ ，真实系数显著偏离随机暴露形成的参照分布。融资约束诊断系数为-0.00789（SE=0.00339， $p=0.0199$ ），方向与融资条件改善机制一致；竞争异质性交互项为-0.0485（ $p=0.117$ ），当前样本未支持“竞争越强、政策效应越大”的预设。

4.4.3 第二轮实际结果

表 4-13 第二轮实际结果

变化内容	第二轮实际结果
任务内容与顺序	区域问题完成真实执行
参数与实验条件	14,196 条观测、1,183 家企业
数据获取方式	源文件、抽取和协议哈希封存
分析与判断方法	$\beta=0.0717$ ； $p=0.00043$ ；前趋势 $p=0.494$ ；置换 $p=0.004$
停止或继续条件	区域复制 16/16 复算通过；全国命题待新数据继续

4.5 最终科学判断

研究由全国命题不可执行转为区域命题完整执行，形成基准估计、动态诊断、稳健性、置换检验和独立复算。区域范围内得到支持：主系数 0.0717， $p=0.00043$ ；前趋势 $p=0.494$ ，轨迹置换 $p=0.004$ ，核心稳健性方向一致。全国市场问题仍需 2022 年以后结果和官方履约名单；闭环增加数据审计、统计计算和证据封存成本。区域复现达到预设支持标准且独立复算 16/16 通过，故本轮停止；全国命题作为取得新数据后的确认性研究继续。

独立复算器不调用主执行脚本，而是使用 NumPy 交替投影消去企业和年份固定效应，重新求解最小二乘估计，并从企业内得分向量重构聚类稳健协方差；随后独立生成相同随机序列，逐项核对 499 个置换系数。16 类检查覆盖 8 组主模型与稳健性模型、8 个事件期系数、处理前联合检验、机制与异质性模型、置换分布、文件哈希和敏感凭证扫描，全部通过；核心系数最大绝对差小于 5×10^{-11} 。

结论准入据此分为三层：区域样本支持“政策暴露与绿色发明专利申请稳定正相关”；融资约束结果只能表述为“与融资条件改善路径一致”；竞争异质性未获支持。全国碳市场因果效应仍需补充 2022 年以后结果、官方履约企业名单及更适合分期处理的识别设计。

4.6 案例适用边界与复现说明

该案例代表社会科学计算实验，能够展示证据检索、数据绑定、执行准入、真实反馈调整、统计执行、质量控制和独立复算；不代表物理仪器控制。当前区域复制结果不能外推为全国碳市场效应。第一轮和第二轮均通过协议冻结、哈希绑定和回执留痕保证调整可追溯，并明确区分当前证据与未来确认任务。

4.7 前端演示中的完整用户流程

4.7.1 从研究问题输入到成果交付

完整用户流程与前述两轮实证研究闭环一一对应。用户在“新研究”页面输入“碳市场能否促进企业高质量绿色技术创新”后，系统先展示研究趋势、可定位证据和研究空白，再生成可切换的候选假设。用户确认主线后，系统将数据需求、变量、方法和停止条件组织为规范研究计划；第一轮执行准入审查显示全国路线暂不具备结果期与官方名单条件，界面随即保留全国确认任务并给出区域复现路线。第二轮完成统计执行与独立复算后，用户可在成果页查看研究计划、结果图表、复算状态、可用于论文的结论及仍需后续验证的命题。

表 4-14 碳市场案例的完整用户流程

用户流程	用户操作	系统呈现与产出	关键控制点
1 研究主题	输入研究问题并限定范围	形成包含政策对象、研究对象、结果变量和范围限定的问题卡	研究者确认问题边界
2 证据发现	查看碳市场、绿色专利和融资约束相关证据	显示全文片段、来源位置及证据适用条件	证据来源与多样性核验
3 趋势与空白	审阅现有研究关注点与识别缺口	形成研究趋势、证据缺口和候选研究方向	研究空白须由证据支持
4 候选假设	切换查看 H1、H2 和 H3	呈现主效应、机制诊断和边界条件及其可证伪表述	假设与原问题一致性审查
5 假设选择	确认“碳政策暴露—高质量绿色创新”为主线	冻结核心研究命题和待检验关系	保留人工研究方向选择权
6 方案生成	审阅数据候选、变量字典、样本范围、方法和停止条件	生成数据与识别方案及规范研究计划	读取结果前冻结协议
7 第一轮反馈	查看全国路线的结果期和官方名单门状态	阻断全国效应估计，并提出区域公开复现路线	未通过硬条件不得生成结果
8 第二轮执行	确认调整范围后查看主回归、事件研究、稳健性、置换、机制和异质性结果	形成统计结果、诊断记录和独立复算结论	结果与协议、数据哈希绑定
9 成果交付	查看研究计划、图表、复算状态和论文初稿	区分本轮可用结论与待新数据验证的全国命题	结论强度由证据准入状态限定

4.7.2 前端页面展示




图 4-4 前端页面展示（1）






图 4-5 前端页面展示（2）

4.7.3 人与系统的交互边界

研究者负责提出主题、授权使用本地文献与数据、选择研究方向并确认关键决策；系统负责证据组织、执行准入、协议冻结、统计运行、独立复算和论文材料生成。人工可以在问题确认、假设选择、范围调整和最终结论等节点审阅，但不得在看到结果后无痕修改样本、模型或显著性规则。

5 AI Scientist 系统能力评价与消融实验

5.1 评价目标与统一实验口径

本章评价 HypoWeaver-Qwen 完整科研流程的稳定性、问题忠实度、证据组织能力、执行准入判断和异常停止能力，而不是单独考察底层模型的知识问答水平。每个任务均依次经过证据检索、研究规划、问题审阅和执行就绪判断，只有相关环节共同满足要求才计为通过；所有终止状态均保留在分母中，不以补跑替换失败。

实验题集包含 10 个代表性绿色金融实证问题，覆盖绿色专利质量、ESG 披露与真实减排、环境投资规模与效率、数字化与绿色转型协同、绿色信贷区域差异、融资约束机制、机构关注与漂绿、碳生产率渠道、政策评估前趋势，以及效率改善与绝对排放变化。每题使用 3 个预定种子独立运行，共形成 30 个问题—重复单元。题集、模型、温度、前 6 条证据、知识库快照、并发上限、调用预算和评分规则均在运行前冻结。

评价指标包括研究方案完整度、原研究问题保持能力、研究主题忠实度、证据来源多样性、数据准备判断能力、审查与修正能力以及异常情况下的安全停止能力。各项能力分别报告原始计数与比例，不合成成为可能掩盖能力差异的单一总分；涉及差异估计时，同时报告配对结果和按问题聚类重复抽样得到的 95% 区间。

5.2 端到端系统能力对照

在同一 30 单元框架下，历史整包对照比较基础门控流程与增强审阅闭环。完整系统在研究方案完整、原问题保持、主题忠实和缺输入阻断四项能力上均有提高，其中原问题保持提高 43.3 个百分点；安全停止和证据来源多样性门在两种流程中均全部通过。该对照反映整体流程升级的综合效果，后续单组件消融用于进一步识别具体贡献来源。

表 5-1 系统能力对照

系统能力	基础流程	完整系统	变化
研究方案完整	20/30（66.7%）	29/30（96.7%）	+30.0 个百分点

系统能力	基础流程	完整系统	变化
原研究问题保持	14/30（46.7%）	27/30（90.0%）	+43.3 个百分点
研究主题忠实	17/30（56.7%）	26/30（86.7%）	+30.0 个百分点
缺输入时正确阻断	20/30（66.7%）	29/30（96.7%）	+30.0 个百分点
证据来源多样性门	30/30（100%）	30/30（100%）	全部通过
异常安全停止	30/30（100%）	30/30（100%）	全部通过

配对任务中，原问题保持有 13 个单元由失败转为通过，没有出现反向变化。由于 30 个实验单元来自 10 个问题簇，结果解释同时保留原始分子与分母、Wilson 95%置信区间和按问题聚类的 bootstrap 敏感性区间。

5.3 关键组件消融实验

表 5-2 消融实验

项目	多文献来源控制消融	结构化输出纠错消融	审阅反馈重做消融
实际比较对象	完整审阅闭环与关闭多文献来源控制	完整审阅闭环与关闭结构化输出纠错	完整审阅闭环与关闭审阅反馈重做
保持相同的条件	同一 10 个问题、每题 3 次重复；模型、温度 0.2、前 6 条证据、知识库快照和并发上限相同；仅关闭文献级来源配额。	同一 10 个问题、3 次重复及相同模型、温度、检索证据、知识库和并发设置；仅关闭结构不合格后的自动纠错。	同一 10 个问题、3 次重复及相同模型、温度、检索证据、知识库和并发设置；保留问题保真审阅器，仅关闭审阅拒绝后的重新检索、规划和复审。
评价方法	前 6 条证据至少来自 3 篇文献，且任一文献不超过 2 条；同问题、同重复配对，并按问题成组重复抽样计算 95%区间。	检索、规划、审阅和就绪编译均返回可解析对象；同问题、同重复配对，并按问题成组重复抽样计算 95%区间。	核对暴露、结果、限定条件和变量角色是否保持原问题含义；同问题、同重复配对，并按问题成组重复抽样计算 95%区间。
完整系统结果	30/30 通过（100.0%）	30/30 通过（100.0%）	30/30 通过（100.0%）
对照结果	15/30 通过（50.0%）	26/30 通过（86.7%）	28/30 通过（93.3%）
结论与代价	净贡献+50.0 个百分点，95%区间 +23.3 至+76.7；关闭组件后丢失 15 个通过单元、反向改善 0 个。该机制增加文献级排序约束，仍需人工核查是否牺牲单篇高相关证据。	净贡献+13.3 个百分点，95%区间 0.0 至+26.7；关闭组件后丢失 4 个通过单元、反向改善 0 个。纠错仅在结构不合格时有界触发，不进行无限重试。	净贡献+6.7 个百分点，95%区间 0.0 至+16.7；关闭组件后丢失 2 个通过单元、反向改善 0 个。审阅拒绝时最多增加一轮检索、规划与复审。

5.4 专项能力与运行成本实验

5.4.1 数据准备状态正反对照

系统使用确定性正、负对照验证执行准入机制。缺少许可完整数据资产和变量绑定时，系统阻断执行并列 6 项缺失，不生成统计结果；当许可、哈希、粒度、时间键、连接键和 4 项变量绑定均完整时，系

统允许任务进入执行审查。结果说明该机制既能够在必要信息缺失时正确停止，也能够元数据完整时正常放行。

表 5-3 数据验证结论

输入条件	系统结果	验证结论
无许可完整数据资产、无变量绑定	阻断并列 6 项缺失	不会凭空生成统计结果
许可、哈希、粒度、时间键、连接键和 4 项变量绑定完整	允许进入执行审查	检查机制能够正确放行

5.4.2 Qwen-VL 科研表格处理实验

Qwen3-VL-Plus 完成 6/6 次真实调用。完整页面输入下，3 次调用均正确识别 46/47 个字段，数值准确率为 100%，但同一显著性标记由三星误识别为两星，因此严格全表通过率为 0/3；裁切并定位目标表格后，3 次调用均达到 47/47 字段严格全对。单次输入由 3,081 tokens 降至 1,067 tokens，减少 65.4%，说明“先定位、再抽取”同时改善了严格准确率与上下文成本。

5.4.3 调用效率与上下文成本

在同一 30 单元历史对照框架下，增强审阅闭环通过更具体的修复指令和更精简的上下文减少重复生成：百炼供应商尝试由 97 次降至 79 次，输入 tokens 由 638,385 降至 462,164，减少 27.6%；输出 tokens 由 253,819 降至 173,061，减少 31.8%。服务端耗时受即时负载影响，因此仅作为描述性结果。

5.5 结果解释与能力边界

5.5.1 科学逻辑与技术贡献

系统不以模型自评或回归显著性代替科研能力评价，而是由审阅器逐项核对研究问题中的暴露、结果、限定条件和变量角色。单组件消融显示，多文献来源控制、结构化输出纠错和审阅反馈重做分别影响证据分散、结构可解析性和问题保真能力；关闭后在对应主指标上分别损失 15、4 和 2 个通过单元。问题保真通过并不等同于科学结论成立，而只说明研究计划没有实质性偏离原问题。

5.5.2 未改善部分与新增成本

安全停止在基础流程和增强审阅闭环中均为 30/30，没有观察到额外提升。多文献来源控制不增加模型调用，但增加检索排序约束；结构纠错和反馈重做仅在失败时有界触发，可能增加局部时延与调用次数。结构纠错和反馈重做的 95% 区间下界均为 0；鉴于实验只有 10 个问题簇，本项目同时报告原始计数与区间，不宣称统计显著。

5.5.3 真实失败与可复现边界

本轮完整单组件实验中，生成结构错误和问题角色偏移均未出现，但关闭相应机制后分别出现 4/30 和 2/30 的失败，说明这两类风险仍客观存在。另有 1/30 出现问题保真审阅通过但冻结词表未命中的情况，表明便于复算的关键词规则无法覆盖全部同义词、非连续表达和新术语。该异常保留在分母中，主分析不事后修改裁判规则，待下一轮题集预注册时再扩充词表。

历史整包对照曾记录 1 个根级角色结构未能在预算内修复、2 个变量角色偏移被审查阻断以及 3 个冻结关键词未覆盖同义表达的任务。由于这些结果属于较早的完整流程版本，本文将其作为历史失败边界呈现，不与本轮 30 单元单组件消融合并计算。供应商随机种子只能支持尽力复现，不能保证逐字一致；更换模型、题集或知识库后需要重新验证。

5.6 适用范围、成本与人工责任

5.6.1 适用用户与研究环节

系统面向需要将研究问题转化为可审阅研究计划的绿色金融研究者、数据分析人员和项目评审者，可辅助问题拆解、证据检索、变量与识别设计、执行就绪检查、审阅反馈修订和停止判断，但不替代真实实验、真实数据分析或专家签字。

5.6.2 成本变化

系统通过统一计划字段并自动记录证据和决策链，减少跨文献检索、格式整理和重复人工核对；同时增加检索排序、结构纠错、审阅复审和供应商调用等待成本。研究者仍需核验文献质量、数据许可、变量口径和识别假设。

5.6.3 人工决策与责任边界

科学问题与因果假设是否合理、数据是否获准使用、字段和时间窗如何绑定、识别策略与统计方法是否成立、是否启动真实分析，以及最终结论的伦理与合规责任，均由研究者决定和承担。系统只提供可审阅的建议、证据与阻塞项。

5.6.4 当前不支持的范围

系统尚不能支持无许可完整数据条件下的真实回归或因果估计、实验仪器的自动控制、跨学科或跨知识库性能的直接外推、知识库更新后的免复测部署，以及无需人工审批的自主科学结论。当前证据仅支持绿色金融题集上的研究计划生成、反馈修订和执行准入能力。

5.7 实验结论

实验结果表明，HypoWeaver-Qwen 的改进来自完整科研流程中的证据约束、结构纠错、问题审阅和执行准入，而非某一次模型回答。系统能够更稳定地保持研究问题、组织多来源证据和形成结构化方案，在关键输入不足时正确停止，并通过目标表格定位提高多模态抽取的严格准确率。同时，冻结词表覆盖、供应商随机性和跨领域外推仍构成明确边界，真实数据许可、变量绑定和因果推断的严格性仍需人工把关。

6 工程实现与可复现性

6.1 系统工程实现

HypoWeaver-Qwen 采用前后端分离与服务化架构，将研究任务编排、知识检索和统计执行划分为三个相互协作的服务。 workflow 服务负责研究任务创建、多智能体调度、人工确认、状态管理与成果交付；知识服务负责文献检索、证据定位、知识图谱查询和来源核验；研究执行服务负责依据已确认的分析计划开展统计估计、诊断检验与独立复算。前端工作台统一呈现研究问题、证据、候选假设、审查意见、执行条件及研究结果。

后端使用 Python、FastAPI 和 Pydantic 实现接口与类型化研究对象，使用 NumPy、pandas、SciPy 和 linearmodels 完成数据处理与计量分析。前端使用 React、TypeScript 和 Vite 构建交互界面。研究状态通过 SQLite 和持久化文件保存，知识资产采用独立目录管理，并以只读方式供知识服务访问。

系统以明确的阶段状态和审核条件控制流程推进。研究规划完成后，程序检查候选方案与原始问题的一致性；未通过时，将缺失概念、偏移原因和修订要求写入下一轮上下文，触发有界的重新检索、规划与

复审。进入统计执行前，程序核验数据许可、资产哈希、观测粒度、时间键、连接键和变量绑定。统计执行后，再根据识别诊断、稳健性检验及独立复算结果确定结论允许采用的表述强度。上述判断同时写入任务记录并返回前端，使研究者能够追踪系统继续、修订或停止的具体原因。

6.2 Qwen 与阿里云百炼平台接入

系统采用“百炼云端模型推理+本地研究执行”的运行方式，通过阿里云百炼的 OpenAI 兼容接口调用 Qwen 系列模型。文本模型承担问题理解、证据综合、假设生成、研究设计及一致性审查；Qwen-VL 承担目标科研表格的结构化抽取。统计估计、指标计算和文件校验由本地确定性程序完成。

模型接入由统一适配器管理，通过 DASHSCOPE_API_KEY、QWEN_BASE_URL 和 QWEN_MODEL 配置访问凭证、接口地址及模型标识。正式复现实验应使用冻结记录中的实际模型标识，而不能直接以部署模板的默认模型替代。模型名称、温度、随机种子、调用预算和提示模板版本随实验保存。

上下文工程采用角色化提示模板与结构化对象交接。每个智能体接收当前任务所需的研究问题、约束条件、证据片段和前序审查结果；模型输出须通过字段结构、引用范围及业务规则校验。结构错误只在预设预算内触发修复，未恢复的调用保留失败状态，不进入后续科学执行。

百炼调用证明由脱敏回执与控制台截图共同构成，包含模型名称、请求标识、调用时间和输入输出 token 数量，以便与实验记录交叉核验。API 密钥仅保存在部署环境中，不写入前端、源代码或提交材料。




图 6-1 控制台截图

6.3 数据、模型调用与研究结果追踪

系统以研究任务标识关联输入问题、证据束、研究计划、审查意见、数据资源、执行结果和最终结论。多轮研究分别保存各轮计划、结果及反馈，保留从第一轮发现问题到第二轮调整方案的完整过程，避免后续结果覆盖前序依据。

数据追踪包括来源、许可、下载或获取位置、字段字典、主键、时间范围和 SHA-256 校验值。分析数据与原始数据分开保存，并记录清洗、筛选、变量构造和样本变化。研究协议在统计执行前冻结，明确主要结果变量、处理定义、模型设定、诊断任务及停止条件，使结果能够回溯到具体数据和分析方案。

模型调用记录区分逻辑任务与实际供应商尝试，保留成功、超时、结构失败及修复结果。已有系统能力实验的 30 个单元全部纳入封存清单，79 次供应商尝试均有对应回执，失败单元保留在评价分母中。涉及私有资料的完整上下文与响应保存在受控环境，对外提交材料采用脱敏记录和可核验摘要。

结果追踪同时保留机器可读结果、展示图表和独立复算报告。文件哈希用于检查材料完整性，独立估
计器用于核验数值计算，结论准入规则用于判断结果能够支持何种科学表述，三者共同构成复现依据。

6.4 源代码组织与提交范围

项目代码提交范围覆盖运行工程、知识资产构建、实验执行和结果评价四个部分。完整材料需要同时
包含前后端源代码、上下文工程模板、部署配置、冻结协议与独立复核程序，使评审能够从运行入口追踪
到关键控制逻辑和实验结果。

表 6-1 源代提交用途

提交模块	主要代码或文件	提交用途
工作流与智能体编排	engine.py、definition.py、discovery_planner.py、	展示任务推进、角色分工、问题锚定及审查
	prompts.py	修订闭环
模型接入与结构契约	adapters.py、runtime_config.py、models.py 及相关	复核百炼调用、模型配置和结构化输出校验
	Schema	
证据检索与知识图谱	knowledge_service.py、knowledge_api.py、	复现文献处理、向量检索、来源配额和图谱
	discovery_engine 及知识构建脚本	查询
数据与统计执行	research_engine.py、policy_causal.py、test_dag.py	复现数据准入、计量估计、诊断及稳健性检
		验
独立复算与结论控制	reproducer.py、claim_gate.py、seal.py	核验统计结果、结论等级及成果封存
接口与前端工作台	api.py、research_api.py 及前端完整源码	运行任务接口、研究交互、审核状态与成果
		展示
系统能力与消融实验	系统能力运行器、单组件消融运行器、独立评价	复跑 10 题×3 次实验、组件对照和指标统计
	器及冻结协议	
多模态与真实案例	Qwen-VL 运行及评价脚本、两类实证案例的执行	复现表格抽取、两轮研究反馈和统计复算
	与验证脚本	
环境与部署	Python 依赖文件、前端依赖锁文件、两个	重建服务运行环境
	Dockerfile、Compose 配置及环境变量模板	
测试与使用说明	后端测试、前端测试、接口示例、部署文档及证	验证安装、调用和复现路径
	据索引	

代码包之外，复现材料还需包含许可允许分发的最小知识快照、向量索引及其嵌入模型版本、案例数
据或合规获取说明、变量字典、人工金标准、脱敏调用回执、逐单元结果和文件校验清单。无法分发的资
料应说明访问条件及其对复现范围的影响。

最终打包时，应统一工程根目录和数据路径，处理实验脚本对开发目录的引用，并使知识文件的实际
位置与部署配置一致。当前知识服务的附加依赖仍采用版本范围，正式交付还需记录实际安装版本或镜像
摘要。提交包排除真实密钥、私人运行数据库、无关缓存和未经授权的文献全文；源代码中的通用提示模
板及上下文构造逻辑应保留。

系统主要通过 HTTP 接口提供任务创建、状态查询、阶段推进、人工审核和成果获取功能。工作流接口
采用/api/v1 前缀，知识检索由/v1/search 提供，研究执行由独立服务承接，并可通过 OpenAPI 描述核对
接口字段。

6.5 部署方式与运行环境

系统支持本地运行及 Docker Compose 部署，通过阿里云百炼调用 Qwen，本地完成知识检索、统计执
行与结果存储。完整源代码、环境配置、部署步骤及实验复现方法已随代码包提交，具体见包内 README.md、
README_DEPLOYMENT.md 和 README_REPRODUCE.md。

6.6 可复现实验材料与复跑流程

本项目将复现分为已有结果复核、确定性统计复算和在线模型重跑三个层次。已有结果复核直接读取冻结产物重新计算指标；统计复算根据同一数据和协议重新执行分析；在线模型重跑重新调用百炼，检验完整流程在相同配置下的表现。三类结果分别记录，避免将历史结果回放视为新运行。

复跑依次执行以下步骤：

1. **校验材料。**核对代码版本、依赖记录、冻结协议、数据及知识快照的校验值，确认输入完整、路径可解析、数据许可满足使用条件。
2. **重建环境。**按部署说明安装依赖或构建镜像，配置百炼模型与知识服务，检查嵌入模型和已有向量索引的一致性，并完成健康检查。
3. **复核系统实验。**使用冻结问题集和种子运行系统能力实验。已有协议采用 10 个问题、3 个种子、温度 0.2、前 6 条证据和每篇文献最多 2 条的约束；审查修订最多增加一轮，每个逻辑调用最多进行 3 次供应商尝试。不同版本和单组件消融分别使用各自协议与输出目录。
4. **复核专项与案例。**多模态实验使用原始页面、目标表格图像和 47 字段人工金标准重新评价；真实案例按照冻结的两轮协议执行数据审计、模型估计、识别诊断、稳健性分析与独立复算，核对反馈是否进入下一轮方案。
5. **生成复现报告。**由独立评价器汇总逐单元结果、失败原因、指标和区间估计，并输出数据哈希、运行配置、结果差异及结论准入状态。失败和阻断结果均保留，不进行事后筛选。

7 创新性、应用价值与结论

7.1 科学方法与系统技术创新

HypoWeaver-Qwen 将证据发现、研究空白识别、可证伪假设构建、数据适配、识别条件检查和结论审查组织为连续研究过程，使研究选题、实证设计与结果解释相互约束。真实案例表明，系统不仅能够生成研究方案，也能够识别数据或因果识别条件不足的情形，并将其转化为明确的数据补充和方法改进方向。

技术上，系统以结构化研究对象连接多智能体，通过原问题锚定控制长流程偏移，以执行准入机制连接自然语言方案与真实数据，并利用确定性统计、独立复算和结论准入限制模型的表达强度。多模态处理采用“**目标定位—约束抽取—结构复核**”的处理链，在提取科研表格信息的同时控制字段错位和数值误读风险。

7.2 应用场景与成果转化

系统可用于政策评估、绿色金融与 ESG 研究、产业与区域经济分析、公共管理、企业风险与专利分析，以及高校科研训练。对于拥有内部数据的机构，系统可以将领域资料、政策规则和结构化数据转化为可执行研究任务；在数据暂不完备的场景中，则输出证据基础、数据需求、研究方案和执行阻塞原因。

项目已形成系统原型、科研知识底座、实验问题集、真实研究案例和可复现代码，可进一步转化为 AI Scientist 方法论文、社会科学实证论文、软件著作权及相关发明专利，并部署为科研 SaaS、机构私有化研究平台或高校科研教学工具。系统通过替换领域知识库、变量与方法模板及专业科研工具，可扩展至环境、教育、公共卫生和产业政策等基于观察数据或准实验设计的研究领域。

7.3 结论

HypoWeaver-Qwen 构建了面向社会科学实证研究的证据驱动型 AI Scientist，将可追溯证据、多智能体科研推理、可执行实证设计、统计复核与结论审查贯通为完整流程。系统实验检验了其问题保持、方案生成、执行准入和审查修订

能力；多模态实验验证了科研表格抽取与复核效果；真实案例则展示了系统在证据或识别条件不足时限制因果表达的能力。系统当前主要适用于具有可核验资料、可定义数据条件和明确实证任务的社会科学研究，不能替代研究者完成价值判断、数据授权和最终科学决策。在这一边界内，项目为 Qwen 参与社会科学实证研究提供了可执行、可审查和可复现的实现路径，并具备向其他观察性和准实验研究场景扩展的基础。

参考文献

- [1] GILARDI F, ALIZADEH M, KUBLI M. ChatGPT outperforms crowd workers for text-annotation tasks[J]. *Proceedings of the National Academy of Sciences*, 2023, 120(30): e2305016120.
- [2] WANG H, FU T, DU Y, et al. Scientific discovery in the age of artificial intelligence[J]. *Nature*, 2023, 620(7972):47-60.
- [3] Boiko D A, MacKnight R, Kline B, et al. Autonomous chemical research with large language models[J]. *Nature*, 2023, 624: 570-578.
- [4] Lu C, Lu C, Lange R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. arXiv:2408.06292, 2024.
- [5] Gottweis J, Weng W H, Daryin A, et al. Towards an AI co-scientist[EB/OL]. arXiv:2502.18864, 2025.
- [6] BRAN A M, COX S, SCHILTER O, et al. Augmenting large language models with chemistry tools[J]. *Nature Machine Intelligence*, 2024, 6: 525-535.
- [7] SCHMIDGALL S, SU Y, WANG Z, et al. Agent laboratory: using LLM agents as research assistants[EB/OL]. (2025-01-09)[2026-09-04]. <https://arxiv.org/abs/2501.04227>.
- [8] NATHANI D, MADAAN L, et al. MLGym: a new framework and benchmark for advancing AI research agents[EB/OL]. (2025-02-21)[2026-09-04]. <https://arxiv.org/abs/2502.14499>.
- [9] KORINEK A. Generative AI for economic research: use cases and implications for economists[J]. *Journal of Economic Literature*, 2023, 61(4): 1281-1317.
- [10] Agrawal, Suzgun, Mackey & Kalai (2024). Do language models know when they're hallucinating references? *Findings of EACL 2024*: 912 – 928.
- [11] Cemri et al. (2025). Why do multi-agent LLM systems fail? *NeurIPS 2025 (Spotlight)*. arXiv:2503.13657.
- [12] Christensen & Miguel (2018). Transparency, reproducibility, and the credibility of economics research. *Journal of Economic Literature*, 56(3): 920 – 980.
- [13] Abadie (2020). Statistical nonsignificance in empirical economics. *AER: Insights*, 2(2): 193 – 208.
- [14] Smock, Pesala & Abraham (2022). PubTables-1M: Towards comprehensive table extraction from unstructured documents. *CVPR 2022*: 15620 – 15629.
- [15] Porter, M. E. & vanderLinde, C. Toward a new conception of the environment-competitiveness relationship. *Journal of Economic Perspectives* 9(4), 97 – 118 (1995).
- [16] Popp, D. Induced innovation and energy prices. *American Economic Review* 92(1), 160 – 180 (2002).
- [17] Calel, R. & Dechezleprêtre, A. Environmental policy and directed technological change: Evidence from the European carbon market. *Review of Economics and Statistics* 98(1), 173 – 191 (2016).
- [18] Hadlock, C.J. & Pierce, J.R. New evidence on measuring financial constraints: Moving beyond the KZ Index. *Review of Financial Studies* 23(5), 1909 – 1940 (2010).
- [19] 企业碳信息披露、融资约束与绿色创新补充数据. PLOS ONE Supplementary Information, DOI: 10.1371/journal.pone.0319997.s001 (CC BY 4.0).
- [20] Wei, D. Industry Peer Effect of Corporate Green Innovation. Mendeley Data, Version 1, DOI: 10.17632/rfwny7byp.1 (2025, CC BY 4.0).
- [21] Goodman-Bacon, A. Difference-in-differences with variation in treatment timing. *Journal of Econometrics* 225(2),

254 - 277 (2021).

- [22] Sun,L.&Abraham,S.Estimating dynamic treatment effects in event studies with heterogeneous treatment effects.
Journal of Econometrics 225(2), 175 - 199 (2021).